

DATA QUALITY REPORT

Adult Income Dataset (UCI) — Tappa 1, Volume 1 Beginner

Engagement ID: AL-AUD-2026-BEGINNER-T1
Cliente: Esercitazione Beginner — Volume 1, Tappa 1
Auditor: Alessandro Littera
Data di emissione: 01/10/2026
Stato: Documento finale di tappa (v2 — numeri confermati da esecuzione reale)

1. Oggetto e perimetro

Il presente report documenta l'esito del Data Quality Audit condotto sull'Adult Income Dataset (UCI Machine Learning Repository), primo controllo eseguito nella catena di audit come preconditione a qualunque valutazione successiva del modello (fairness, explainability, robustezza).

2. Sintesi dei risultati

Sezione	Contenuto
Anagrafica dataset	Fonte: UCI Machine Learning Repository (Adult / Census Income Dataset). Data di download: 21/09/2026. 32.561 righe, 15 colonne (split di training). Licenza: pubblico dominio, uso a fini di ricerca/didattici.
Completezza	4.262 celle mancanti (1,31% del totale), concentrate su 3 colonne: workclass (1.836 — 5,64%), occupation (1.843 — 5,66%), native-country (583 — 1,79%). Nessuna delle 12 colonne restanti presenta valori mancanti. I missing sono codificati nel file sorgente con il placeholder '?' anziché come valore nullo nativo — verificato anche a livello di file grezzo, indipendentemente dallo strumento di analisi.
Duplicati e coerenza	24 righe duplicate rilevate su 32.561 (0,07%). Nessun valore fuori range sulla colonna age (17–90, confermato da regola di validazione formale).
Rappresentatività	Distribuzione sbilanciata sulle variabili sensibili: sex 66,92% Male / 33,08% Female; race 85,43% White, 9,59% Black, 3,19% Asian-Pac-Islander, 0,96% Amer-Indian-Eskimo, 0,83% Other. Il tasso di reddito >50K è 30,57% per il gruppo Male contro 10,95% per il gruppo Female — quasi triplo. Osservazione riportata come base per l'approfondimento di fairness in una fase successiva dell'audit, non come conclusione in questa fase.
Sbilanciamento del target	Il target income risulta sbilanciato: 75,92% delle osservazioni ≤50K, 24,08% >50K. Caratteristica strutturale della distribuzione del reddito nella popolazione censita, non un difetto del dato — da tenere in considerazione nella fase di addestramento (es. class weighting) e nell'interpretazione di qualunque metrica di accuratezza.
Esito	Nessuna anomalia bloccante (soglia di riferimento: 30% di missing su una singola colonna; massimo osservato 5,66%). Tre osservazioni non bloccanti registrate: (1) 4.262 valori mancanti concentrati su 3 colonne, gestibili in fase di modellazione (es. imputazione o esclusione mirata) — severità bassa; (2) 24 righe duplicate, severità bassa; (3) rappresentatività demografica non uniforme su sex e race con un divario di oltre 2,5x nel tasso di reddito elevato tra i gruppi — severità media, raccomandato approfondimento con un Fairness Audit dedicato prima di qualunque utilizzo del modello in un contesto decisionale reale.

3. Raccomandazione

Il dataset è idoneo a proseguire nella pipeline di audit. Si raccomanda che l'eventuale utilizzo del modello addestrato su questi dati in un contesto decisionale reale (es. credito, selezione del personale) sia subordinato a un Fairness Audit dedicato, dato il divario di oltre 2,5x nel tasso di reddito elevato rilevato tra i gruppi sex. Si raccomanda inoltre una strategia esplicita di gestione dei missing (imputazione o esclusione documentata) prima dell'addestramento di qualunque modello di produzione.

4. Riferimenti e allegati

Registro delle Evidenze (DOC-021) — voci EVD-001 → EVD-005.

Working Paper di Test e Campionamento (DOC-023) — voci TEST-001 → TEST-005.

Report tecnico di profiling automatico: [data_quality_report.html](#).

5. Limitazioni

Il presente audit è un esercizio didattico su dataset pubblico; la rappresentatività è valutata rispetto alla sola popolazione descritta nel dataset, non rispetto a una popolazione target aziendale reale, che andrebbe definita caso per caso in un incarico effettivo.