

# EXPLAINABILITY AUDIT REPORT

Random Forest su dati Titanic — spiegazioni con SHAP e LIME

|                   |                                     |
|-------------------|-------------------------------------|
| Engagement ID     | AL-AUD-2026-SIMULAZIONE-TITANIC-1-3 |
| Cliente           | SIMULAZIONE-TITANIC-1-3             |
| Data di emissione | 06/10/2026                          |
| Versione          | 1.0                                 |
| Auditor           | Alessandro Littera                  |
| Riservatezza      | Confidenziale                       |

## 1. Sintesi

Oggetto della verifica è la spiegabilità di un classificatore Random Forest che predice la sopravvivenza dei passeggeri del Titanic (891 casi), costruito dall'auditor come sistema sotto esame. Lo scenario è una simulazione: il sistema è trattato come se supportasse una decisione di priorità ad alto rischio, per applicare i criteri di trasparenza e spiegabilità dell'AI Act (artt. 13, 14, 86).

Le spiegazioni sono tecnicamente ottenibili, coerenti con le probabilità del modello (scarto di additività massimo 0,000000) e stabili tra ripetizioni di LIME. Mostrano però che le decisioni dipendono in modo dominante dal sesso del passeggero, con SHAP e LIME concordi, e fanno emergere quattro ulteriori punti di attenzione. Sono stati emessi cinque rilievi: uno Major, due Minor, due Observation.

| Voce                                                       | Esito                                                                               |
|------------------------------------------------------------|-------------------------------------------------------------------------------------|
| Giudizio complessivo (scenario ipotizzato ad alto rischio) | Non conforme, per il rilievo Major FIND-001; per il resto conforme con osservazioni |
| Prestazione del modello                                    | Accuratezza 0,8213 con deviazione standard 0,0243 su 20 divisioni dei dati          |
| Spiegabilità tecnica                                       | Ottenibile con SHAP e LIME; additiva e stabile                                      |
| Rilievi                                                    | FIND-001 Major; FIND-002 e FIND-003 Minor; FIND-004 e FIND-005 Observation          |

## 2. Ambito e metodo

### 2.1 Inquadramento del sistema

| Domanda                   | Risposta                                                                                                 |
|---------------------------|----------------------------------------------------------------------------------------------------------|
| Che tipo di sistema è?    | Classificatore tabellare (Random Forest), costruito dall'auditor                                         |
| Che decisione supporta?   | Simulazione di una decisione di priorità di salvataggio, a solo scopo didattico                          |
| Chi è impattato?          | Gruppi per sesso, classe di viaggio ed età, quest'ultima proxy dello status economico                    |
| Che accesso ha l'auditor? | Completo (dati, modello, codice): applicabile SHAP TreeExplainer                                         |
| Rischio secondo l'AI Act? | Nessuna classificazione reale; trattato come alto rischio per gli obblighi di trasparenza e spiegabilità |

## 2.2 Dati e modello

| Elemento          | Dettaglio                                                                                              |
|-------------------|--------------------------------------------------------------------------------------------------------|
| Dataset           | train.csv della competizione Titanic (Kaggle), 891 righe e 12 colonne                                  |
| Feature usate (9) | Pclass, Sex_female, Age, SibSp, Parch, Fare, Embarked_C, Embarked_Q, Embarked_S                        |
| Escluse           | PassengerId, Name, Ticket (identificativi) e Cabin (mancante nel 77,1% dei casi)                       |
| Imputazione       | Age con la mediana e Embarked con la moda, calcolate solo sui dati di addestramento                    |
| Divisione         | 75% addestramento (668) e 25% test (223), stratificata sul target; seme 42 per la divisione principale |
| Modello           | Random Forest, 200 alberi, random_state uguale al seme                                                 |

## 2.3 Procedura

- Controllo della qualità del dato su tutta la popolazione (EVD-003).
- Prestazione su 20 divisioni ripetute e confronto con la regola "donna = sopravvive" (EVD-004, EVD-008).
- Spiegazione globale con SHAP sul test set della divisione principale (EVD-005).
- Spiegazione locale con SHAP su 3 casi scelti con regola dichiarata prima dell'esecuzione: due errori tra i 5 più sicuri e il caso corretto con probabilità più vicina a 0,5 (EVD-006).
- Spiegazione locale con LIME sugli stessi casi, ripetuta su 10 semi (EVD-007).
- Controlli su quattro ipotesi formulate prima dell'esecuzione e su un sottogruppo anomalo (EVD-008, EVD-009).

## 3. Risultati

### 3.1 Qualità del dato

| Controllo                | Risultato                                      |
|--------------------------|------------------------------------------------|
| Dimensioni               | 891 righe, 12 colonne; PassengerId unico       |
| Valori mancanti          | Age 177 (19,9%), Cabin 687 (77,1%), Embarked 2 |
| Duplicati                | 0                                              |
| Target                   | 61,62% non sopravvissuti, 38,38% sopravvissuti |
| Sopravvivenza per sesso  | Donne 74,20% (314), uomini 18,89% (577)        |
| Sopravvivenza per classe | Prima 62,96%, seconda 47,28%, terza 24,24%     |
| Tariffa uguale a zero    | 15 righe, tutte maschili                       |

### 3.2 Prestazione

Su 20 divisioni casuali l'accuratezza media è 0,8213 (deviazione standard 0,0243, minimo 0,7713, massimo 0,8789). La regola banale "donna = sopravvive" ottiene in media 0,7926. Nel confronto accoppiato la Random Forest guadagna in media 0,0287 punti (deviazione standard 0,0223) ed è migliore in 18 divisioni su 20.

La divisione principale (seme 42), sulla quale sono calcolate tutte le spiegazioni, ha dato 0,7489, inferiore al minimo delle 20 divisioni. Le spiegazioni descrivono quindi un modello addestrato su una divisione sfavorevole; il valore di riferimento per la prestazione è la distribuzione, non il singolo numero (FIND-005).

### 3.3 Spiegazione globale

Il grafico mostra, per ciascuna feature, quanto ogni valore spinge la probabilità di sopravvivenza verso l'alto (destra) o verso il basso (sinistra), con il colore che indica il valore della feature.




Figura 1 — SHAP summary plot sul test set (n=223, seme 42).

| Feature    | SHAP  medio | Direzione osservata nel grafico                                                                      |
|------------|-------------|------------------------------------------------------------------------------------------------------|
| Sex_female | 0,2024      | Donne tra +0,10 e +0,46; uomini tra -0,25 e -0,07; le due modalità non si sovrappongono              |
| Pclass     | 0,0914      | Terza classe verso la morte, prima classe verso la sopravvivenza                                     |
| Fare       | 0,0744      | Tariffe alte in prevalenza positive; alcune tariffe basse con contributi positivi fino a circa +0,27 |
| Age        | 0,0586      | Età basse positive (fino a circa +0,46), età alte negative (fino a circa -0,26)                      |
| SibSp      | 0,0259      | Valori alti negativi                                                                                 |
| Embarked_S | 0,0214      | Imbarco a Southampton lievemente negativo                                                            |
| Embarked_C | 0,0163      | Imbarco a Cherbourg lievemente positivo                                                              |
| Parch      | 0,0157      | Effetto contenuto, prevalentemente positivo per valori alti                                          |
| Embarked_Q | 0,0073      | Effetto minimo                                                                                       |

Il sesso pesa più del doppio della feature successiva. Nel contesto storico del dataset il risultato riproduce un fenomeno documentato; in un sistema reale di alto rischio lo stesso pattern costituirebbe un uso potenzialmente discriminatorio (FIND-001).

### 3.4 Spiegazioni locali con SHAP

La probabilità di base del modello è 0,3821; ogni caso parte da lì e i contributi delle feature sommano esattamente la probabilità finale.

| Caso            | Descrizione                                       | Esito                                                | Contributi principali                                                                             |
|-----------------|---------------------------------------------------|------------------------------------------------------|---------------------------------------------------------------------------------------------------|
| A<br>indice 271 | Uomo, terza classe, 25 anni, tariffa 0, imbarco S | Sopravvissuto; predetto morto con probabilità 0,0000 | Sex_female -0,1781; Fare -0,1101; Pclass - 0,0438; Age -0,0245. Tutti i contributi sono negativi. |

| Caso            | Descrizione                                              | Esito                                                   | Contributi principali                                                                                                   |
|-----------------|----------------------------------------------------------|---------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|
| B<br>indice 199 | Donna, seconda classe, 24 anni, tariffa 13,00, imbarco S | Deceduta; predetta sopravvissuta con probabilità 0,9950 | Sex_female +0,4623; Pclass +0,1314; SibSp +0,0364; Age +0,0200; Fare -0,0195.                                           |
| C<br>indice 62  | Uomo, prima classe, 45 anni, 1 familiare, tariffa 83,475 | Deceduto; predetto morto con probabilità 0,4950         | Sex_female -0,1834; Fare +0,1379; Pclass +0,1010; Age +0,0474; SibSp +0,0361.<br>Spinte opposte che quasi si annullano. |

Nel caso A il modello assegna un contributo fortemente negativo alla tariffa zero. L'analisi del sottogruppo mostra 1 sopravvissuto su 15 (6,7%), contro il 18,89% di tutti gli uomini: con 15 righe non è possibile distinguere un segnale reale da un effetto del caso, e il modello lo tratta come una regola con confidenza massima (FIND-002). Nei casi A e B la probabilità è estrema (0,0000 e 0,9950) pur con predizione errata, segno di probabilità non calibrate (FIND-003).

### 3.5 Confronto con LIME

LIME è stabile: su 10 semi la deviazione standard dei pesi è tra 0,003 e 0,010, il segno di ogni feature non cambia e Sex\_female è la prima per peso assoluto 10 volte su 10 in tutti e tre i casi. La stabilità non implica però accordo con SHAP.

| Caso | Spearman sui valori assoluti | Segno concorde | Top 3 in comune | Segno discorde su                                 |
|------|------------------------------|----------------|-----------------|---------------------------------------------------|
| A    | 0,73                         | 7 su 9         | 3 su 3          | SibSp, Embarked_Q (contributo SHAP vicino a zero) |
| B    | 0,48                         | 7 su 9         | 2 su 3          | Age, Embarked_Q                                   |
| C    | 0,90                         | 7 su 9         | 3 su 3          | Age, SibSp                                        |

I due metodi concordano sull'essenziale (prima il sesso, poi la classe) e divergono sulle feature secondarie. Il disaccordo più rilevante riguarda il segno di Age nei casi B e C. Per arbitrarlo è stata variata la sola età dei casi lasciando il resto invariato: in B e C la risposta del modello sostiene il segno di SHAP. LIME discretizza l'età in quattro fasce (fino a 22, 22-29, 29-36, oltre 36 anni): la discretizzazione è una spiegazione plausibile del disaccordo, sostenuta per il caso C e non per il caso B (FIND-004).

### 3.6 Ipotesi formulate prima dell'esecuzione

| Ipotesi                                                                           | Criterio di verifica                                                          | Esito                                                                                                                                                     |
|-----------------------------------------------------------------------------------|-------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| H1 — Sex_female ha il maggiore  SHAP  medio                                       | Prima posizione nella classifica globale                                      | Confermata: 0,2024 contro 0,0914 di Pclass                                                                                                                |
| H2 — L'importanza di Pclass e Fare si divide perché le due feature sono correlate | Spearman almeno 0,5 in valore assoluto e Pclass +20% senza Fare               | Confermata con riserva: Spearman -0,686 e Pclass +41,9%, ma salgono anche le altre feature (da +4,7% a +52,2%); l'assorbimento specifico non è dimostrato |
| H3 — La Random Forest supera la regola banale, ma di poco                         | Differenza media accoppiata positiva e maggiore della sua deviazione standard | Confermata: +0,0287 contro 0,0223; 18 divisioni su 20                                                                                                     |
| H4 — Il disaccordo sul segno di Age dipende dalla discretizzazione di LIME        | Risposta del modello alla sola variazione dell'età                            | Sostenuta per il caso C, non per il caso B                                                                                                                |

## 4. Rilievi

| ID       | Requisito      | Rilievo                                                                      | Gravità | Azione correttiva proposta                                                                                                                                |
|----------|----------------|------------------------------------------------------------------------------|---------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| FIND-001 | AI-006, AI-009 | Dipendenza dominante dall'attributo protetto sesso, con SHAP e LIME concordi | Major   | Documentare e giustificare l'uso di Sex; valutare un modello senza l'attributo o con vincoli di equità e misurare i divari tra gruppi; sorveglianza umana |

| ID       | Requisito        | Rilievo                                                                                     | Gravità     | Azione correttiva proposta                                                        |
|----------|------------------|---------------------------------------------------------------------------------------------|-------------|-----------------------------------------------------------------------------------|
| FIND-002 | AI-011           | Regola appresa su un sottogruppo di 15 righe (Fare = 0) con confidenza massima              | Minor       | Raccogliere più dati o trattare il gruppo come categoria separata                 |
| FIND-003 | AI-010, AI-011   | Probabilità non calibrate (0,0000 e 0,9950 in predizioni errate)                            | Minor       | Calibrare le probabilità e non mostrare quelle grezze agli operatori              |
| FIND-004 | AI-009 (art. 86) | SHAP e LIME divergono su feature secondarie e sul segno di Age                              | Observation | Definire il metodo di spiegazione fornito agli interessati e dichiararne i limiti |
| FIND-005 | AI-011           | Prestazione dipendente dalla divisione dei dati ( $0,8213 \pm 0,0243$ ; 0,7489 sul seme 42) | Observation | Riportare la distribuzione dell'accuratezza nella documentazione tecnica          |

Dettaglio, evidenze collegate e stato nel Finding and Non-Conformity Register (DOC-025).

## 5. Limiti dell'audit

- Simulazione didattica su dati storici: non esiste un cliente reale né soglie di accettazione concordate, e il giudizio complessivo vale per lo scenario ipotizzato.
- Un solo modello, un solo algoritmo e un solo metodo di imputazione.
- Le spiegazioni locali riguardano tre casi scelti con regola dichiarata, non un campione rappresentativo.
- Le spiegazioni si riferiscono alla divisione principale (seme 42), la cui prestazione è sfavorevole rispetto alla media.
- LIME è stato eseguito con una sola configurazione (fasce a quartili, 5000 campioni per spiegazione); SHAP con TreeExplainer.
- Non sono stati misurati la calibrazione complessiva né i divari tra gruppi (equità); non è stata eseguita alcuna mitigazione.
- Il sottogruppo con tariffa zero conta 15 righe: le conclusioni su di esso sono indicative.
- Le spiegazioni locali sono fornite in forma tabellare, non come grafici di forza.

## 6. Riproducibilità

| Elemento                                     | Valore                                                                                |
|----------------------------------------------|---------------------------------------------------------------------------------------|
| Dataset                                      | train.csv, SHA256<br>7d118fef8b6ccf7f81111877bc388536f7b1e498a655e3d649d19aaa010e9f6f |
| Librerie                                     | shap 0.52.0, lime 0.2.0.1, scikit-learn 1.9.1, pandas 2.3.3                           |
| Modello                                      | RandomForestClassifier, 200 alberi, random_state = seme, soglia di decisione 0,5      |
| Semi                                         | Divisione principale 42; divisioni ripetute 0-19; LIME 0-9                            |
| Valori di imputazione (divisione principale) | Mediana di Age 29,0; moda di Embarked S                                               |
| Tempi di esecuzione                          | 20 divisioni 4,9 s; SHAP globale 1,2 s; spiegazioni locali e LIME 3,2 s               |