

Fairness Audit Report

COMPAS, livelli A e B · SIMULAZIONE-COMPAS-1-2

Voce	Dettaglio
Engagement ID	AL-AUD-2026-SIMULAZIONE-COMPAS-1-2
Cliente	SIMULAZIONE-COMPAS-1-2
Auditor	Alessandro Littera
Data e versione	05/10/2026 · v1.0 · Bozza
Natura del documento	Simulazione su dati pubblici di terzi: non è un incarico commissionato né un giudizio sul prodotto commerciale

1. Sintesi

L'audit ha misurato se i punteggi di rischio di recidiva di COMPAS, e un modello di riferimento semplice, producono errori diversi per gruppi diversi. Lo squilibrio storico documentato da ProPublica si riproduce: i non recidivi African-American sono classificati ad alto rischio circa 1,9 volte più spesso dei Caucasian (FPR 0,4485 contro 0,2345 sulle 7.214 righe del file). Il risultato è robusto a un'anomalia nei dati e non dipende dall'uso della razza come input.

Sono emersi quattro rilievi (DOC-025): due Major (anomalia sulle etichette dopo il 01/04/2014; disparità di FPR e FNR tra gruppi) e due Observation (calibrazione approssimata con scostamenti ai punteggi 3-4; licenza dei dati non dichiarata).

2. Perimetro e metodo

Elemento	Dettaglio
Sistema	COMPAS, stima del rischio di recidiva; popolazione di Broward County (Florida), screening 2013-2014
Dati	compas-scores-two-years.csv, repository pubblico ProPublica, 7.214 righe, 53 colonne. SHA256 c451db85908b2f7fef1d83203bedf6b71ecda0d5af468d82ae62178f91d0cc7d (03/10/2026). Licenza non dichiarata: applicati in via prudenziale i termini del Data Store ProPublica
Gruppi	African-American e Caucasian (gli altri gruppi hanno numeri troppo piccoli)
Livello A	Solo gli output: punteggi COMPAS (1-10). Soglie: Medium+High (punteggio 5 o più) e High (8 o più)
Livello B	Regressione logistica a cinque variabili (età, precedenti, reati minori, grado del reato), razza esclusa, divisione 70/30 con seme 42; ripetizione su 20 divisioni
Popolazioni	Completa e corretta (screening prima del 01/04/2014), per misurare l'effetto dell'anomalia
Metriche	FPR, FNR, precisione (PPV), tasso di selezione, Demographic Parity Difference, Equalized Odds Difference; intervalli di confidenza bootstrap 95% (2.000 ricampionamenti, seme 42) e di Wilson
Strumenti	Fairlearn 0.14.0, AIF360 0.6.1, scikit-learn 1.9.1, pandas 2.3.3; Python 3.13; ogni metrica verificata con calcolo manuale dalla matrice di confusione (scarto 0)

3. Qualità del dato

Le righe con screening dal 01/04/2014 hanno etichetta di recidiva a due anni quasi sempre positiva: 0,997 contro 0,362 prima, sul file grezzo (1.007 righe). Nel campione filtrato dei due gruppi sono 773 righe (African-American 498, tasso 0,998; Caucasian 275, tasso 0,996), con 1 solo non recidivo per gruppo. Il volume per trimestre scende da 1.096 (T1 2014) a 318 (T2 2014). Il quadro è coerente con un'inclusione selettiva dei soli recidivi dopo quella data, ma la causa non è accertata.

Effetti misurati: i tassi di recidiva di base e la precisione risultano gonfiati; FPR e FNR non cambiano (Tabella 1). Un modello addestrato sul file così com'è segnala quasi il doppio delle persone (48% e 26% contro 24% e 8,5%).

4. Risultati sui punteggi COMPAS (livello A)

La replica sulle 7.214 righe produce esattamente le matrici di contingenza pubblicate da ProPublica, il che valida la pipeline di calcolo. Soglia: punteggio Medium o High.

Tabella 1. Metriche per gruppo, soglia Medium+High

Popolazione	Gruppo	n	Non recidivi	FPR	FNR	PPV
Completa (7.214)	African-American	3.696	1.795	0,4485	0,2799	0,630
Completa (7.214)	Caucasian	2.454	1.488	0,2345	0,4772	0,591
Corretta	African-American	3.134	1.794	0,4487	0,2784	0,546
Corretta	Caucasian	2.130	1.487	0,2340	0,4883	0,486

Tabella 2. Divari tra gruppi (African-American meno Caucasian), 6.150 righe, intervallo di confidenza 95%

Popolazione	Metrica	Divario	IC 95% inferiore	IC 95% superiore
Completa	FPR	0,214	0,180	0,245
Completa	FNR	-0,197	-0,234	-0,161
Completa	PPV	0,038	-0,001	0,077
Corretta	FPR	0,215	0,182	0,246
Corretta	FNR	-0,210	-0,255	-0,164
Corretta	PPV	0,060	0,014	0,105

Sui 5.278 casi filtrati, il Demographic Parity Difference è tra 0,160 e 0,248 e l'Equalized Odds Difference tra 0,185 e 0,219 (due soglie, due popolazioni): tutti sopra la soglia di attenzione di 0,10, che è un criterio di lavoro e non una soglia normativa. I divari di FPR e FNR sono identici con e senza le righe anomale. Il divario di PPV è piccolo e statisticamente debole; la sua variazione tra le due popolazioni non è distinguibile dal rumore.

Calibrazione




Figura 1. Tasso di recidiva a due anni per punteggio e gruppo, con intervalli di Wilson al 95%.

Le curve dei due gruppi sono vicine e gli intervalli si sovrappongono quasi ovunque: a parità di punteggio, la frequenza di recidiva è simile. Ai punteggi 3 e 4 gli African-American recidivano più dei Caucasian (0,419 contro 0,341 e 0,460 contro 0,396 sul completo), con intervalli che si toccano. Ai punteggi alti i numeri dei Caucasian sono piccoli (64 persone al punteggio 10), quindi gli intervalli sono molto larghi.

5. Confronto con un modello di riferimento (livello B)

La regressione logistica, che non usa la razza, è stata confrontata con COMPAS sulle stesse righe di test (Tabella 3). Per separare il confronto dall'effetto della soglia, la regressione è stata anche forzata a segnalare la stessa quota di persone di COMPAS, su 20 divisioni train/test (Tabella 4).

Tabella 3. Divisione 70/30 con seme 42 (Medium+High per COMPAS, soglia 0,5 per la regressione)

Popolazione	Sistema	Segnalati AA / Cauc	Divario FPR (IC 95%)	Divario FNR (IC 95%)	Accur.
Completa	Regressione	48,3% / 26,4%	0,165 (0,109; 0,221)	-0,212 (-0,289; -0,137)	0,664
Completa	COMPAS	54,8% / 32,8%	0,186 (0,127; 0,246)	-0,193 (-0,271; -0,118)	0,641
Corretta	Regressione	23,9% / 8,5%	0,055 (0,019; 0,090)	-0,242 (-0,316; -0,160)	0,701
Corretta	COMPAS	53,3% / 28,7%	0,195 (0,133; 0,253)	-0,213 (-0,304; -0,127)	0,675

Tabella 4. Controllo a soglia abbinata, medie su 20 divisioni (minimo e massimo tra parentesi)

Popolazione	Sistema	Segnalati	Divario FPR medio	Rapporto FPR
Completa	COMPAS	48,0%	0,205 (0,167; 0,256)	1,93
Completa	Regressione, soglia 0,5	40,3%	0,163 (0,101; 0,208)	2,06
Completa	Regressione, soglia abbinata	48,3%	0,198 (0,143; 0,233)	1,92
Corretta	COMPAS	45,0%	0,201 (0,154; 0,243)	1,94
Corretta	Regressione, soglia 0,5	19,6%	0,089 (0,055; 0,127)	3,05
Corretta	Regressione, soglia abbinata	45,2%	0,191 (0,144; 0,222)	1,92

Il divario più piccolo della regressione sul campione corretto (0,055) non indica maggiore equità: dipende dal fatto che con soglia 0,5 segnala molte meno persone, e la divisione con seme 42 era la più favorevole delle 20. A pari quota di segnalati, regressione e COMPAS hanno lo stesso divario di FPR e lo stesso rapporto (circa 1,9). La soglia sposta la disparità tra assoluta e relativa: con poche persone segnalate il divario assoluto si riduce, ma il rapporto sale (3,05).

6. Interpretazione

- Riproduzione. lo squilibrio storico di ProPublica si riproduce: i non recidivi African-American hanno un FPR circa doppio, e i recidivi Caucasian un FNR più alto di circa 20 punti.
- Robustezza. i divari di FPR e FNR non cambiano togliendo le righe con etichette anomale; cambiano solo tassi di base e precisione.
- Razza esclusa. un modello semplice e trasparente, senza la razza tra gli input, ha a pari quota di segnalati la stessa disparità di COMPAS. Escludere l'attributo protetto non la elimina.
- Conflitto tra criteri. la calibrazione approssimata e l'uguaglianza degli errori non possono valere insieme quando i tassi di recidiva di base differiscono (circa 12 punti tra i gruppi, in entrambe le popolazioni).
- Conclusione. la conclusione non è dichiarare il sistema equo o iniquo, ma rendere esplicito quale criterio è soddisfatto (calibrazione approssimata) e quale no (uguaglianza degli errori), con le conseguenze misurate per ciascun gruppo.

7. Rilievi

ID	Requisito	Sintesi	Gravità	Rischio
FIND-001	AI-006	Etichette anomale dopo il 01/04/2014 (886 righe, 14,4% dei due gruppi)	Major	Medio
FIND-002	AI-005	Disparità di FPR e FNR a pari quota di segnalati, anche senza la razza in input	Major	Alto
FIND-003	AI-005	Calibrazione approssimata con scostamenti ai punteggi 3-4	Observation	Basso
FIND-004	AI-006	Licenza del dataset non dichiarata	Observation	Basso

Dettaglio, evidenze e azioni correttive proposte: *Finding and Non-Conformity Register (DOC-025)*, *Evidence Register (DOC-021)*, *Testing and Sampling Workpaper (DOC-023)*.

8. Raccomandazioni

- 1. verificare la provenienza delle etichette dopo il 01/04/2014 ed escludere o ricostruire quelle righe, documentando la scelta.
- 2. definire e documentare il criterio di equità adottato e la soglia come decisione di policy, con monitoraggio periodico di FPR e FNR per gruppo.
- 3. garantire supervisione umana effettiva sulle decisioni basate sul punteggio e ottenere conferma scritta dei termini d'uso dei dati.

9. Limitazioni

- Due soli gruppi; popolazione di una sola contea e di un solo biennio.
- L'etichetta misura il riarresto entro due anni, non la recidiva effettiva, e può risentire di intensità di controllo diverse tra i gruppi.
- Livello A: solo gli output, quindi si dimostra uno squilibrio ma non se ne spiega la causa. Il confronto con il livello B non è uno a uno: COMPAS usa input che nel dataset non sono disponibili.
- Campioni di test di circa 1.300-1.600 righe: intervalli ampi; la causa dell'anomalia sulle etichette non è accertata.
- Nessuna mitigazione è stata testata; nessun dato del cliente su supervisione umana, valutazione dei diritti fondamentali o livello di accuratezza dichiarato.

10. Riferimenti

- ProPublica, «How We Analyzed the COMPAS Recidivism Algorithm» e repository compas-analysis (github.com/propublica/compas-analysis).
- Regolamento (UE) 2024/1689: requisiti collegati nella checklist DOC-020 (AI-005, AI-006, AI-011).