AL — AI GOVERNANCE AUDIT

ROBUSTNESS AUDIT REPORT

Rapporto tecnico di audit di robustezza — classificatore di cifre MNIST

Engagement ID	AL-AUD-2026-SIMULAZIONE-MNIST-1-4
Cliente (simulato)	SIMULAZIONE-MNIST-1-4
Sistema auditato	Rete convoluzionale a 10 classi per la lettura di cifre scritte a mano (MNIST), addestrata dall'auditor su 5 semi
Scenario d'uso ipotizzato	Lettura automatica di cifre su moduli (ad esempio importi); classificazione AI Act da determinare
Data di emissione	08/10/2026
Versione / Stato	1.0 — Versione emessa
Auditor	Alessandro Littera
Riservatezza	Confidenziale

Rapporto tecnico di audit. Non è un documento del toolkit (DOC-001→031): confluirà come allegato nel futuro Rapporto Finale (DOC-027). Registri collegati: DOC-021, DOC-023, DOC-025.

1. Sintesi

Esito: il sistema è accurato sul dato pulito (0,979 in media) e tollera bene il rumore casuale moderato, ma non è robusto a perturbazioni mirate. Con un attacco FGSM di ampiezza 0,15 l'accuratezza media scende a 0,267, contro 0,950 con rumore casuale di pari norma e pari ampiezza massima. Il test di robustezza contro l'attacco mirato risulta non conforme rispetto al requisito AI-011 (accuratezza, robustezza e cybersecurity testate).

Rilievi: 6 in totale — 1 Major, 2 Minor, 3 Observation (dettaglio in DOC-025 e nella sezione 5).

Raccomandazioni principali:

- Non impiegare il sistema, senza mitigazioni, in contesti dove un utente può avere interesse a ingannarlo o dove la lettura ha effetto finanziario non controllato da una persona.
- Rendere requisito di rilascio la verifica su più addestramenti e per singola classe: la media su un solo modello nasconde sia la variabilità tra addestramenti sia le cifre più fragili.
- Prima di ogni uso reale, estendere i test ad attacchi più forti (PGD) e a scenari senza accesso al modello: questo audit misura il caso peggiore con accesso completo (white-box) e con un attacco debole.

2. Oggetto, perimetro e metodo

Sistema	CNN: Conv2D(16, 3×3) → MaxPooling → Flatten → Dense(64) → Dense(10, softmax); ottimizzatore Adam, 3 epoche, batch 128
Dati	MNIST: 60.000 immagini di addestramento e 10.000 di test, 28×28 in scala di grigi, valori scalati in [0, 1]
Accesso	Completo (pesi e gradienti), perché il modello è stato addestrato dall'auditor. È una stima prudente (peggiore) rispetto a un attaccante senza accesso al modello
Criteri	Regolamento (UE) 2024/1689, art. 15 (accuratezza, robustezza, cybersicurezza); requisiti di checklist AI-011, AI-006, AI-009, AI-023 (DOC-020)

Perturbazioni	Rumore gaussiano (deviazione standard = eps); rumore a segno casuale (ogni pixel ±eps); attacco FGSM tramite ART (Adversarial Robustness Toolbox). Immagini ritagliate a [0, 1] dopo la perturbazione
Ampiezze (eps)	0,02 – 0,05 – 0,10 – 0,15 – 0,20 – 0,25 – 0,30; per FGSM, griglia fine esplorativa 0,11 – 0,14
Ripetizioni	5 semi di addestramento (0–4), ciascuno valutato sulle 10.000 immagini di test
Misure	Accuratezza; intervallo di Wilson al 95% per il singolo risultato (circa ±1 punto al massimo); intervallo t al 95% sui 5 semi per le medie; soglia di rottura = primo eps con accuratezza < 0,50
Ambiente	Python 3.13.5; TensorFlow 2.21.0; Keras 3.15.1; ART 1.20.1; numpy 2.3.5; pandas 2.3.3; scikit-learn 1.9.1

Le previsioni sui risultati sono state scritte nel piano di audit prima del primo addestramento (sezione 4). I controlli non previsti dal piano originale (griglia fine FGSM, accuratezza per classe, matrice di confusione) sono dichiarati esplorativi.

3. Risultati

3.1 Accuratezza sul dato pulito e robustezza a eps = 0,15

Condizione	Accuratezza media	IC95 sui 5 semi	Min–max
Dati puliti (riferimento)	0,9791	0,9768–0,9814	0,9774–0,9820
Rumore gaussiano (std = 0,15)	0,9258	0,8999–0,9518	0,9044–0,9593
Rumore a segno casuale (±0,15)	0,9497	0,9340–0,9653	0,9331–0,9673
Attacco FGSM (eps = 0,15)	0,2673	0,1643–0,3704	0,2043–0,3674

Valori medi sui 5 semi; l'intervallo t riflette la variabilità tra addestramenti (n = 5), quella di campionamento del test set è di circa ±1 punto per seme.

Il divario tra rumore casuale e attacco mirato è molto ampio: a eps 0,15 la differenza appaiata tra segno casuale e FGSM è 0,6823 (IC95 0,5668–0,7979). Il rumore gaussiano è peggiore di quello a segno casuale in tutti e 5 i semi (2,4 punti in media, IC95 1,3–3,5).

3.2 Curva di accuratezza contro l'ampiezza della perturbazione

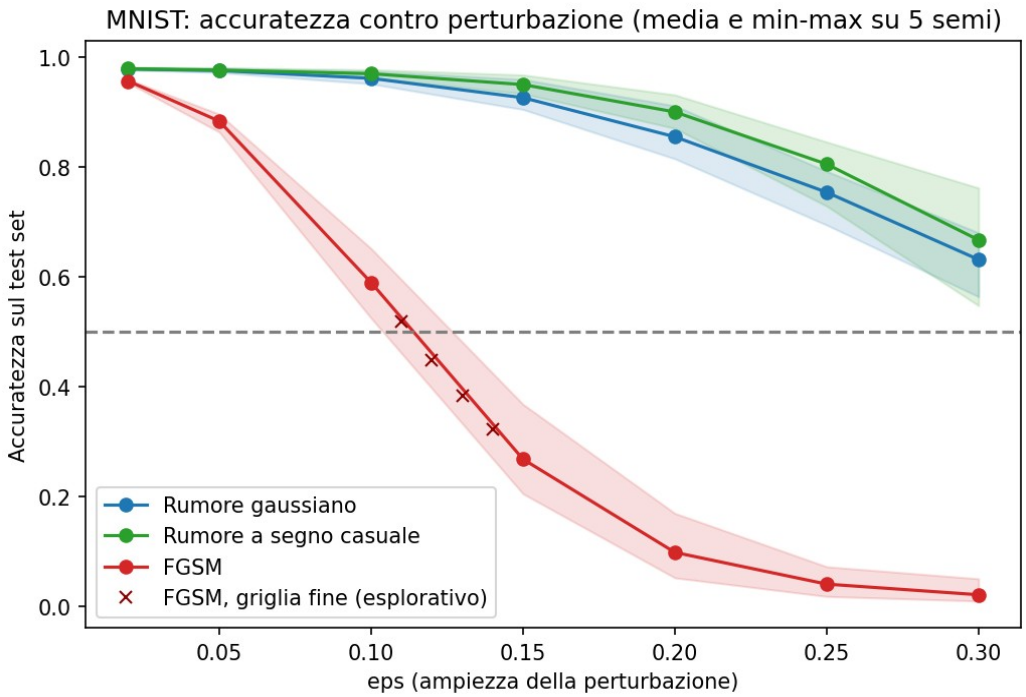


Figura 1 — Media e intervallo min–max sui 5 semi. La linea tratteggiata è la soglia di rottura (0,50).

eps	Rumore gaussiano	Rumore a segno casuale	FGSM
0,02	0,9781 (0,9765–0,9805)	0,9785 (0,9767–0,9816)	0,9562 (0,9531–0,9591)
0,05	0,9754 (0,9717–0,9800)	0,9761 (0,9734–0,9802)	0,8830 (0,8631–0,8959)
0,10	0,9611 (0,9510–0,9741)	0,9695 (0,9619–0,9769)	0,5890 (0,5241–0,6510)
0,11	—	—	0,5179 (0,4458–0,5926)
0,12	—	—	0,4478 (0,3738–0,5328)
0,13	—	—	0,3821 (0,3090–0,4732)
0,14	—	—	0,3224 (0,2556–0,4186)
0,15	0,9258 (0,9044–0,9593)	0,9497 (0,9331–0,9673)	0,2673 (0,2043–0,3674)
0,20	0,8546 (0,8146–0,9111)	0,8998 (0,8699–0,9311)	0,0975 (0,0512–0,1688)
0,25	0,7535 (0,6938–0,7918)	0,8047 (0,7283–0,8452)	0,0397 (0,0173–0,0715)
0,30	0,6309 (0,5633–0,6799)	0,6666 (0,5469–0,7615)	0,0204 (0,0089–0,0496)

Tabella — media (min–max) sui 5 semi. Le righe 0,11–0,14 sono un controllo esplorativo sul solo FGSM.

3.3 Soglia di rottura

Con la griglia grossolana, in tutti i semi la soglia di rottura (accuratezza < 0,50) è già superata a eps 0,15 e non ancora a eps 0,10. La griglia fine la colloca tra 0,11 e 0,13: eps 0,13 per i semi 0 e 4, eps 0,11 per i semi 1, 2 e 3 (media sui semi: attraversa 0,50 tra 0,11 e 0,12). In termini concreti, eps 0,11 equivale a spostare ogni pixel di circa 28 livelli di grigio su 255. Col rumore casuale la soglia non viene raggiunta in nessun seme fino a eps 0,30 (valore minimo 0,547 per il rumore a segno casuale).

Seme	Pulito	Gaussiano (0,15)	Segno casuale (0,15)	FGSM (0,15)	Soglia FGSM
0	0,9783	0,9044	0,9331	0,3674	0,13
1	0,9820	0,9593	0,9673	0,2105	0,11

Seme	Pulito	Gaussiano (0,15)	Segno casuale (0,15)	FGSM (0,15)	Soglia FGSM
2	0,9774	0,9171	0,9478	0,2043	0,11
3	0,9797	0,9307	0,9549	0,2060	0,11
4	0,9781	0,9176	0,9453	0,3485	0,13

Tabella — accuratezza per seme a eps 0,15 e soglia di rottura FGSM (griglia fine).

3.4 Confronto a pari intensità

La grandezza della perturbazione è confrontabile: la norma L2 media a eps 0,15 è praticamente identica per i tre tipi, e il rumore a segno ha anche la stessa ampiezza massima di FGSM. La differenza di effetto dipende quindi dalla direzione (casuale contro mirata sul gradiente), non dalla grandezza.

Perturbazione (eps 0,15)	Norma L2 media	Ampiezza massima (Linf)
FGSM	3,10	0,15
Rumore a segno casuale	3,10	0,15
Rumore gaussiano	3,07	0,80

3.5 Esempi

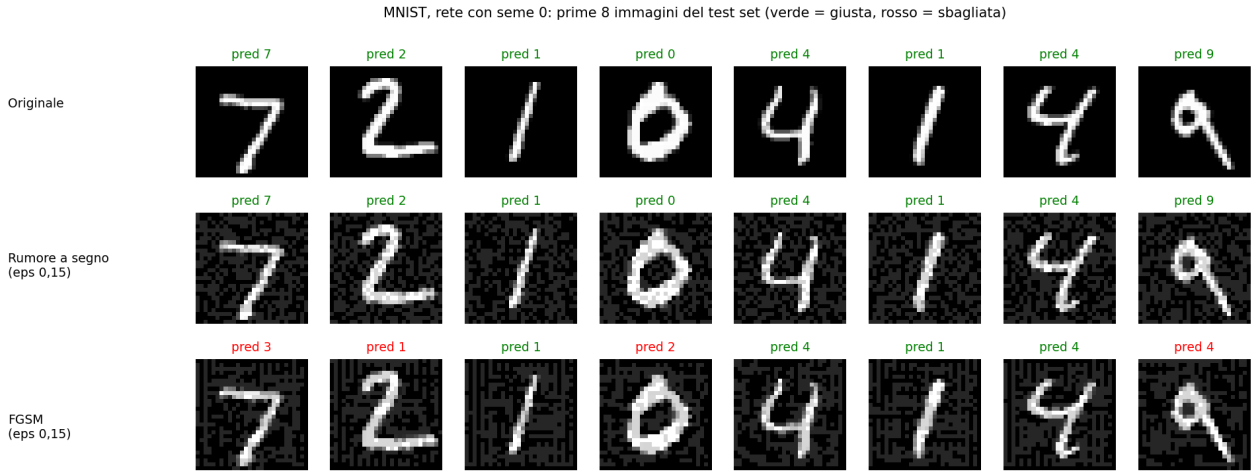


Figura 2 — Seme 0, prime 8 immagini del test set, eps 0,15. Verde = predizione corretta, rosso = errata.

La perturbazione a eps 0,15 è visibile (una grana grigia sullo sfondo nel rumore, una trama a strisce in FGSM), ma le cifre restano leggibili per una persona. Il modello con rumore a segno le legge tutte correttamente; con FGSM ne sbaglia 4 su 8. Il seme 0 è uno dei due più robusti: con gli altri semi gli errori sarebbero più numerosi.

3.6 Robustezza per classe (eps 0,10)

Cifra	Pulito	Rumore a segno casuale	FGSM
0	0,9894	0,9865	0,7043
1	0,9930	0,9944	0,6745
2	0,9748	0,9736	0,5973
3	0,9836	0,9784	0,6315
4	0,9896	0,9853	0,7065
5	0,9800	0,9870	0,6578
6	0,9745	0,9701	0,6944

Cifra	Pulito	Rumore a segno casuale	FGSM
7	0,9784	0,9749	0,6755
8	0,9671	0,9255	0,2940
9	0,9590	0,9171	0,2513

Tabella — accuratezza media sui 5 semi per classe a eps 0,10. La media delle dieci classi sotto FGSM (0,589) coincide con il dato complessivo.

Le cifre 9 (0,251) e 8 (0,294) sono molto più fragili delle altre (0,60–0,71) sotto FGSM, e perdono circa 4 punti anche col rumore casuale, mentre le altre ne perdono meno di 1. Lo schema non vale per ogni addestramento: è netto nei semi 0, 3 e 4; nel seme 1 un'altra classe scende a 0,279, più in basso sia della cifra 8 sia della cifra 9, e nel seme 2 vale solo per la cifra 9. La fragilità non dipende dalla numerosità delle classi nell'addestramento (cifre 8 e 9 sono vicine alla media).

Destinazione degli errori sotto FGSM (somma sui 5 semi): le immagini della cifra 9 sono classificate come 7 nel 41,9% degli errori e come 4 nel 28,4%, e queste due destinazioni sono le prime due in tutti e 5 i semi; le immagini della cifra 8 finiscono soprattutto come 2 (28,7%), 3 (22,9%) e 5 (20,7%), con le prime due sempre comprese in {2, 3, 5}. Sul dato pulito la cifra 9 sbaglia già verso 4 e 7 (28% ciascuna), mentre gli errori della cifra 8 sono più sparsi. Il risultato è coerente con l'ipotesi che le cifre fragili siano vicine ad altre cifre specifiche, ma non la dimostra: la causa resta non accertata.

4. Verifica delle previsioni fissate in anticipo

Ipotesi	Previsione	Esito	Dato
H1	Accuratezza pulita ≥ 0,98 su tutti i semi	Smentita	Media 0,9791; solo il seme 1 (0,9820) la raggiunge
H2	Con rumore casuale a eps 0,15 l'accuratezza cala di meno di 3 punti (per ogni seme)	Smentita	Gaussiano −5,3 punti in media (4 semi su 5 sopra soglia); segno casuale −2,9 in media (2 semi su 5 sopra soglia). Sulla sola media il segno casuale rientrerebbe di poco
H3	FGSM a eps 0,15 porta l'accuratezza sotto 0,50	Confermata	0,2673 in media; da 0,2043 a 0,3674 per seme
H4	Soglia di rottura FGSM sotto eps 0,15; col rumore mai raggiunta	Smentita (regola del piano)	Con la griglia del piano la soglia è 0,15 in tutti i semi; la griglia fine (esplorativa) la colloca tra 0,11 e 0,13. Il rumore non scende mai sotto 0,50 fino a 0,30
P5	La cifra 5 (meno numerosa nel training) non è la più fragile sotto FGSM	Confermata	La cifra più fragile è la 9; la 5 è al 5° posto su 10
P6	Almeno il 50% degli errori di 8 e 9 finisce in 2 classi	Confermata	51,6% (cifra 8, margine sottile) e 70,2% (cifra 9); riferimento per distribuzione uniforme: 22%

H1–H4 sono nel piano di audit; P5 e P6 negli addendum, scritti prima dei rispettivi controlli. Il criterio «per ogni seme» di H2 è quello applicato dallo script scritto prima dell'esecuzione.

5. Rilievi

ID	Gravità	Rilievo	Azione proposta
FIND-001	Major	Il modello cede a perturbazioni mirate piccole (FGSM, eps 0,15: accuratezza 0,267; soglia di rottura tra 0,11 e 0,13), a parità di norma col rumore che lascia l'accuratezza a 0,950	Valutare misure di mitigazione e ripetere il test; prima di un uso con effetto finanziario provare attacchi più forti e senza accesso al modello

ID	Gravità	Rilievo	Azione proposta
FIND-002	Minor	Fragilità concentrata su poche classi (in media le cifre 8 e 9), nascosta dall'aggregato; le classi fragili variano col seme	Includere il controllo per classe nei test di robustezza; approfondire le destinazioni di errore
FIND-003	Minor	La robustezza dipende dal seme di addestramento (FGSM a 0,15 tra 0,204 e 0,367)	Verifica su più addestramenti come requisito di rilascio, con un livello minimo di robustezza
FIND-004	Observation	Il degrado col rumore casuale non è trascurabile (−2,9 e −5,3 punti a eps 0,15); gaussiano peggiore del segno casuale a pari norma	Definire con il cliente il calo accettabile in base alla qualità reale delle scansioni
FIND-005	Observation	Accuratezza pulita e robustezza al rumore non predicono la robustezza avversariale	Prevedere test avversariali dedicati; non usare indicatori sostitutivi
FIND-006	Observation	Fonte, licenza e checksum di riferimento del dataset non documentati nell'evidenza	Documentare provenienza, licenza e checksum nel fascicolo tecnico

6. Raccomandazione sull'uso

Il divario tra rumore casuale e attacco mirato è significativo? Sì, in modo netto e statisticamente solido sui 5 semi (differenza appaiata 0,68 a eps 0,15, intervallo 0,57–0,80).

Il sistema sarebbe utilizzabile dove un utente può avere interesse a ingannarlo? No, non senza mitigazioni. Un attaccante con accesso al modello porta l'accuratezza media sotto 0,30 con perturbazioni che una persona legge senza difficoltà, e supera la soglia di rottura con ampiezze (0,11–0,13) più piccole di quelle (0,15) alle quali il rumore casuale lascia ancora l'accuratezza oltre 0,92. L'accesso completo è uno scenario prudente: un attaccante reale potrebbe non averlo, e questo audit non misura quel caso.

Per un uso ordinario (nessun avversario, scansioni di qualità non degradata) il sistema è accettabile solo se il cliente definisce il calo di accuratezza ammesso (FIND-004) e se esiste un controllo umano sugli importi di maggior effetto.

7. Limiti dell'audit

- L'attacco usato è FGSM, un attacco debole: un risultato sfavorevole è informativo, un risultato favorevole non avrebbe dimostrato robustezza. Non sono stati eseguiti PGD, attacchi senza accesso al modello (black-box) né test di trasferibilità.
- Il modello è stato addestrato dall'auditor su MNIST come caso didattico: non è il modello di un cliente e MNIST non rappresenta scansioni reali di moduli.
- Cinque semi danno intervalli larghi sulle medie avversariali; il numero di semi limita la precisione dei confronti fra addestramenti.
- La causa della fragilità delle cifre 8 e 9 non è accertata: la matrice di confusione è coerente con l'ipotesi di vicinanza ad altre cifre, ma non la dimostra.
- Non è stata valutata la documentazione d'uso né l'esistenza di difese presso un cliente (requisiti AI-009 e AI-023): non applicabili alla simulazione.
- L'audit fornisce una ragionevole, non assoluta, sicurezza e non costituisce parere legale né sostituisce la valutazione di conformità prevista dall'AI Act.

8. Riferimenti normativi e metodologici

- Regolamento (UE) 2024/1689 (AI Act), art. 15: livelli adeguati di accuratezza, robustezza e cybersicurezza per i sistemi ad alto rischio lungo il ciclo di vita, comprese misure contro input

progettati per indurre il modello in errore (esempi avversariali). La classificazione del sistema simulato non è stata determinata.

- ISO 19011: principi e metodologia dell'audit (evidenze, campionamento, reporting).
- Goodfellow, Shlens, Szegedy (2015), «Explaining and Harnessing Adversarial Examples»: definizione dell'attacco FGSM.
- Registri di audit collegati: DOC-021 (12 evidenze), DOC-023 (12 test: 3 Conforme, 5 Parziale, 1 Non Conforme, 3 N/A), DOC-025 (6 rilievi).